

## 1.1 动机

标签数据是稀少并且昂贵的，但是监督学习，往往需要大量的标签数据，而如果不带标签训练数据，往往陷入无监督学习的境地，而无监督学习得到的特征往往是朴素的，没有特定的含义与语义，这对于特定的任务而言，往往是不够的。作者提出了一种通过限制条件，即 **domain** 相关的知识来约束输出空间，来进行监督学习的方法。

## 1.2 原理

对于传统的监督学习而言有：

$$f^* = \arg \min_{f \in \mathcal{F}} \sum_{i=1}^n \ell(f(x_i), y_i)$$

其中 $f$ 是要学习的函数， $x_i$ 表示输入， $y_i$ 表示 $x_i$ 对应的 **label** 监督信息， $\ell$ 为 **loss function**。

而在这篇论文中，学习的一种表示是：

$$\hat{f}^* = \arg \min_{f \in \mathcal{F}} \sum_{i=1}^n g(x_i, f(x_i)) + R(f)$$

其中 $g$ 表示的是 **domain** 相关的一种约束函数，通过这样一种约束，达到监督学习的目的。 $R$ 是正则项，这里的正则项主要的目的是为了避免函数 $f$ 是一个平凡解。因为 **domain** 相关的约束对于特定的问题而言，往往是必要不充分的，因此如果仅仅依靠 **domain** 来约束的话，很有可能导致学习的 $f$ 是一个平凡解。所以引入了正则项 $R$ ，这里可以看到，学习的过程中是不包含标签 $y_i$ 的，因此是一种 **label-free** 的监督学习。其中 $g$ 函数是需要在特定的任务下设计的。